

# 基于改进粒子群算法的无人机航迹规划

刘春玲, 冯锦龙, 田玉琪, 张琪珍

(大连大学信息工程学院, 辽宁 大连 116622)

**摘要:** 标准粒子群算法在解决无人机航迹规划问题上容易陷入局部最优解。针对上述问题, 提出了随机位置突变的自适应粒子群算法。算法选择基于凸函数的自适应惯性权重递减模型, 能够同时兼顾全局搜索和局部精细搜索, 引入早熟判定机制和位置突变机制。通过该机制使得群体符合位置突变条件时, 各个粒子将会在保留记忆和速度的基础上, 跳跃到一个新的位置进行搜索, 增加了群体的多样性, 具备了跳出局部最优的能力。通过 MATLAB 仿真表明, 基于随机位置突变的自适应粒子群算法收敛效果有显著提升, 并且改进算法的复杂度没有明显增加。所提算法在复杂环境下的适用性要远远优于标准粒子群算法, 在航迹规划问题上具备可行性和优越性。

**关键词:** 粒子群优化算法; 随机位置突变; 自适应惯性权重; 三维航迹规划

**中图分类号:** TP391.9      **文献标识码:** B

## Based on UAV Track Planning of Improved Particle Swarm Optimization Algorithm

LIU Chun-ling, FENG Jin-long, TIAN Yu-qi, ZHANG Qi-zhen

(College of Information Engineering, Dalian University, Dalian Liaoning 116622, China)

**ABSTRACT:** The standard particle swarm optimization algorithm is easy to fall into the local optimal solution in solving the UAV trajectory planning problem. Aiming at this problem, an adaptive particle swarm algorithm with random position mutation is proposed. The algorithm selects an adaptive inertia weight-decreasing model based on convex functions, which can take into account both global development and local fine search. Then, a precocious decision mechanism and a position mutation mechanism were introduced. When the group meets the condition of position mutation, each particle will jump to a new position to search on the basis of retaining memory and speed, which increases the diversity of the group and has the ability to jump out of the local optimum. The MATLAB simulation experiments show that the convergence effect of the adaptive particle swarm based on random position mutation is significantly improved, and the complexity of the improved algorithm is not greatly improved. In addition, the applicability of the algorithm in complex environments is far better than the standard algorithm. It has feasibility and superiority in the problem of trajectory planning.

**KEYWORDS:** Particle swarm optimization algorithm; Random position mutation; Adaptive inertia weights; 3D track planning

### 1 引言

无人机航迹规划是为了顺利完成飞行任务, 在综合地理环境、各种威胁以及飞行长度等诸多因素下, 给无人机规划出一条令人满意的空间飞行轨迹<sup>[2]</sup>, 其本质是在连续空间内路径寻优问题。一条最优航迹线路, 可以提升无人机执行任

务成功率。

在以往解决航迹规划的过程中, 涌现出了多种算法。主要分为传统算法和现代群智能算法。前者有人工势场法<sup>[3]</sup>、A\*<sup>[4]</sup>和Dijkstra算法<sup>[5]</sup>等。它们的优点是发展成熟, 理论基础扎实, 缺点在于高维空间内容易出现组合爆炸和局部最优的问题。二维空间的路径规划效果好, 应用于三维环境代价较高。蚁群算法和粒子群算法是现代群智能算法的典型代表, 它们在解决三维空间的全局航迹规划上表现出了独特的优势, 并且可以适应各类复杂空间<sup>[6, 7]</sup>。相较其它群智能算

基金项目: 辽宁省教育厅面上项目( LJKZ1184)

收稿日期: 2022-03-07    修回日期: 2022-03-13

法,粒子群算法简单易实现并且具有较强的鲁棒性,对种群大小敏感性不高,参数少,前期收敛速度快等优点。但是粒子群算法在解决航迹规划问题上存在容易陷入局部最优的问题。针对这个问题,文献[8]在粒子位置初始化时使用了混沌的方法,使得粒子的分布更为随机无序,提高了种群的多样性。文献[9]从惯性权重入手,设计了自适应的惯性权重,在迭代初期惯性权重较大,群体具备较强的全局搜索能力,随着迭代的进行逐渐减小,证明了该方法提高了粒子的收敛效率和收敛效果。文献[10]对比了多种自适应的惯性权重模型,得出结论是,问题复杂程度越高,惯性权重应该递减越慢,得到的收敛结果质量越高。参数的重新设置可以提升算法性能,但是无法保证解的全局最优性。此外,绝大多数研究采用了混合算法的思想来提高粒子群算法的收敛性能。文献[11]引入了遗传算法的变异机制,文献[12]引入了天牛须所搜算法,每次迭代时粒子对环境空间进行判断,文献[13]引入了动态适应度函数,利用此函数设计了一种轨迹规划器,用基于 Bresenham 算法的粒子群算法解决问题。混合算法在增加种群多样性方面提升明显,但是却没有了粒子群算法本身的简单高效特点,混合算法复杂度的提升更为明显。基于这种现状,从提高粒子群算法本身来进行切入,设计了一种新的惯性权重自适应递减的机制,对每一代的最优值进行监测,加入粒子群体早熟判定机制和位置突变机制,寻找到最优路径。

## 2 无人机航迹规划模型

### 2.1 环境模型

研究无人机航迹规划问题,前提需要搭建一个无人机飞行的环境区域,即三维数字地图。而本次研究是针对野外的复杂环境,因此设置静态地形和以雷达为代表威胁区域即可。

静态地形采用山峰函数<sup>[14]</sup>进行模拟生成,如式(1)所示

$$z(x, y) = \sum_{i=1}^s h_i \times e^{-\left(\frac{x-x_i}{x_{si}}\right)^2 - \left(\frac{y-y_i}{y_{si}}\right)^2} \quad (1)$$

式(1)中  $z(x, y)$  表示坐标  $(x, y)$  处的高度值,  $s$  是山峰的总个数,  $(x_i, y_i)$  表示第  $i$  个山峰的中心坐标,  $h_i$  为地形参数,控制山峰高度,  $x_{si}$  和  $y_{si}$  分别表示第  $i$  个山峰沿着  $x$  轴和  $y$  轴方向的衰减量,这对参数控制山峰坡度。

威胁源形式多样,为了便于研究,取雷达代表威胁区域。采用半球模型来表示雷达威胁区域,如式(2)所示

$$W_i(x, y, z) = \begin{cases} \sum_i (x-x_i)^2 + (y-y_i)^2 + (z-z_i)^2 = R_i^2 \\ z \geq z_i \end{cases} \quad (2)$$

式中,  $W_i(x, y, z)$  表示第  $i$  个雷达的探测区域,  $(x, y, z)$  为第  $i$  个雷达中心所在的位置,  $R_i$  是第  $i$  个雷达模型的半径。在现实中,还需要最大探测半径  $R_{\max}$  和有效探测半径  $R_{\min}$  这两组数据做来限制。

### 2.2 适应度函数设置

适应度函数用来评价一条航迹优劣,直接决定最后寻优结果的质量。如果某条航迹曲线与山峰曲面有接触,那么这条航迹的代价将是无穷大,即该航迹不是可行解,本文综合权衡航迹长度代价、雷达威胁代价和偏航角代价这三个具有实际效益因素进行适应度函数设置,如式(3)所示

$$F = k_1 \times f_L + k_2 \times f_W + k_3 \times f_A \text{ 且 } k_1 + k_2 + k_3 = 1 \quad (3)$$

其中  $F$  表示航迹代价,  $f_L$  表示航迹长度代价,  $f_W$  表示雷达威胁代价,  $f_A$  表示偏航角代价。  $k_1$ ,  $k_2$  和  $k_3$  分别表示  $f_L$ ,  $f_W$  和  $f_A$  的权重常数。在此特别说明,由于这三个代价的单位和取值范围不同,因此在加权之前数据经过标准化处理,去掉了单位,代价数据归一化至区间  $[0, 1]$  上。

#### 2.2.1 航迹长度代价

假设在粒子群算法中设置航迹点数为  $n$ , 经过寻优搜索,得到的  $n$  个离散的航迹点并不是直接可飞行航迹,需要在此基础上进行插值和拟合处理,得到一条光滑的曲线。经插值处理,由  $n$  个点扩充至  $N$  个节点,故航迹长度可以用式(4)表达

$$f_L = \sum_{i=1}^{N-1} \sqrt{(x_{i+1} - x_i)^2 + (y_{i+1} - y_i)^2 + (z_{i+1} - z_i)^2} \quad (4)$$

其中  $(x_i, y_i, z_i)$  表示第  $i$  个空间节点的坐标,  $(x_{i+1}, y_{i+1}, z_{i+1})$  表示第  $(i+1)$  个空间节点的坐标,  $N$  插值后的节点总数。当  $N$  较大时,可以用各个直线段距离之和近似代替拟合后的曲线距离。

#### 2.2.2 雷达威胁代价

若无人机经过敌方雷达的探测范围,则可能会被敌方发现并发起攻击,因此,无人机在飞行过程中需要和雷达保持一个合适距离。本文中规定被雷达探测的概率如下式(5)

$$P = \begin{cases} 1 & L_{k,m} \leq R_{\min} \\ \frac{1}{L_{k,m}} & R_{\min} < L_{k,m} \leq R_{\max} \\ 0 & R_{\max} < L_{k,m} \end{cases} \quad (5)$$

其中  $R_{\min}$  和  $R_{\max}$  分别表示雷达的有效探测半径和最大探测半径,  $L_{k,m}$  表示航迹点  $(x_m, y_m, z_m)$  和雷达中心  $(x_k, y_k, z_k)$  的直线距离。距离公式如式(6)

$$L_{k,m} = \sqrt{(x_m - x_k)^2 + (y_m - y_k)^2 + (z_m - z_k)^2} \quad (6)$$

因此,雷达威胁代价模型如下式(7)

$$f_W = \sum_{k=1}^W \sum_{m=1}^N P \quad (7)$$

其中,  $W$  表示雷达数量,  $N$  表示插值后的航迹点总数。

#### 2.2.3 偏航角代价

自身性能约束是无人机飞行的必要考虑因素,由于飞行高度有限,故取偏航角作为自身约束的代表。由于无人机飞行速度高,当实际转弯角大于无人机的最大转弯角时,无人机将存在安全隐患。偏航角的计算将在两个相邻航迹段构成的平面内进行。计算公式如下式(8)和(9)

$$\theta = \cos^{-1} \frac{\langle a_i, a_{i+1} \rangle}{|a_i| \times |a_{i+1}|} \quad (8)$$

$$a_i = (x_{i+1} - x_i, y_{i+1} - y_i, z_{i+1} - z_i) \quad (9)$$

其中  $a_i$  表示第  $i$  段航迹向量的坐标表示  $(x_i, y_i, z_i)$  表示第  $i$  个航迹点的三维坐标。 $|a_i|$  表示该向量的模长。第  $i$  段航迹的偏航角代价如式(10)所示

$$angle_i = \begin{cases} \theta & \theta \leq \theta_{\max} \\ \frac{\theta - \theta_{\max}}{\pi - \theta_{\max}} & \theta > \theta_{\max} \end{cases} \quad (10)$$

其中  $\theta_{\max}$  表示最大转弯角。可以得到全局偏航角代价如式(11)所示

$$f_A = \sum_{i=1}^{N-1} angle_i \quad (11)$$

### 3 自适应惯性权重与随机位置突变

#### 3.1 标准粒子群算法

基本粒子群优化(Particle Swarm Optimization, PSO)算法(简称粒子群算法)是一种典型的智能群集优化算法,它由 Eberhart 和 Kennedy 于 1995 年提出。结合航迹规划问题,一个粒子即代表一条可飞航迹。各个粒子在飞行过程中所经历的最佳位置被称为个体极值,记为  $P_{best}$ ,整个粒子群体所经历的最优位置被称为全局极值,记为  $G_{best}$ 。群体中的所有粒子都经过这两个极值以及自身移动惯性来保持更新,从而产生新一代群体。在基本粒子群算法基础上引入惯性权重的概念,并且应用到粒子的更新中,取得了更好的优化效果。加入固定惯性权重的粒子群算法被称为标准粒子群算法。在标准粒子群算法中,粒子的速度和位置更新公式分别如下所示

$$V_i(t+1) = \omega \times V_i(t) + C_1 \times r_1 \times [P_i(t) - X_i(t)] + C_2 \times r_2 \times [P_g(t) - X_i(t)] \quad (12)$$

$$X_i(t+1) = X_i(t) + V_i(t+1) \quad (13)$$

式中,假定群体中共有  $N$  个粒子,群体进行  $T$  次迭代。 $V_i(t)$  表示第  $i=(1, 2, 3, \dots, N)$  个粒子在  $t=(1, 2, 3, \dots, T)$  代的速度, $X_i(t)$  表示第  $i$  个粒子在第  $t$  代的位置, $\omega$  是惯性权重,控制自身惯性对搜索的影响程度, $C_1$  和  $C_2$  是学习因子,控制自身认知和社会认知的影响程度, $r_1$  和  $r_2$  均取自区间  $[0, 1]$  的随机数,控制着移动的随机性。 $P_i(t)$  表示第  $i$  个粒子经过  $t$  代更新所经历的最佳位置, $P_g(t)$  表示经过  $t$  代更新后,群体所经历的最佳位置。另外,粒子是在一定范围内逐渐向最优位置靠拢的,粒子的速度和位置都要保持在合理的范围内,即  $V_i(t) \in [V_{\min}, V_{\max}]$ ,同时  $X_i(t) \in [X_{\min}, X_{\max}]$ 。本文中,所有的越界值都赋予其最近的边界值。

#### 3.2 随机位置突变的自适应粒子群算法

##### 3.2.1 自适应惯性权重

在众多参数中,惯性权重对算法性能的影响最为明显。 $\omega$  越大,则粒子惯性影响程度越高,全局搜索效果越好,相反地,其值越小,变相地提升了自身认知和社会认知的影响程

度,局部搜索效果就越好。因此,可以先让粒子获得较大的  $\omega$  值,尽可能地进行搜索,随着迭代的进行,自适应地减小  $\omega$  值,增强粒子进行局部搜索的能力。经过前人学者的检验,这是一种缓解过早陷入局部最优的有效办法。惯性权重的更新公式如式(14)

$$\omega = W_{\max} + (W_{\max} - W_{\min}) \times \Phi \quad (14)$$

其中,  $W_{\max}$  是惯性权重最大值,  $W_{\min}$  是对应的惯性权重最小值,  $\Phi$  是由当前迭代次数  $t$  和迭代总次数  $T$  构成的递减模型且满足  $\Phi \in [0, 1]$ 。

利用不同的  $\Phi$  模型对 Rastrigin 函数求最小值,经过大量的实验统计后,本文拟采取如式(15)的自适应递减模型整合到改进的算法中

$$\Phi = -\left(\frac{t}{T}\right)^2 + 1 \quad (15)$$

##### 3.2.2 随机的位置突变

为了进一步解决粒子群算法陷入局部最优的问题,无限增加粒子数量理论上可以实现全位置的全遍历,但是却不具备实际意义,因为计算量会急剧增加。另外一种办法就是增加粒子的种群多样性,也就是位置分布的多样性。本文中,为了增加种群多样性,进而跳出局部最优,加入了随机位置突变方法。位置突变如式(16)所示

$$X_i(t+1) = rand(1, D) \times (X_{\max} - X_{\min}) + X_{\min} \quad (16)$$

式中,  $rand(1, D)$  表示  $(1 \times D)$  的矩阵序列,并且矩阵中的元素均属于  $[0, 1]$  的随机数,  $X_{\max}$  和  $X_{\min}$  分别表示位置的上界和下界。

在算法开始时,加入了全局极值重复量标记 flag, flag 初值设为 0,每完成一次迭代,将本代的  $G_{best}$  和上一代进行比较,如果相差值小于某个固定参数  $\varepsilon$ ,则 flag 增加 1。当 flag 到达最大迭代次数的 10% 并且当前迭代次数小于最大迭代次数的 70% 时,被认为该代粒子满足位置突变条件,按照式(16)进行位置突变,突变后 flag 归 0。10% 和 70% 的设置是多次实验得到的最优控制参数,在保证后期收敛的前提下,最大限度地增加种群的多样性。

综合上述 2.2.1 和 2.2.2 小节的论述,改进的粒子群算法流程图如上图 1 所示。




图 1 三种算法的收敛曲线

### 3.3 改进的粒子群算法仿真

本次实验的在于检验本文所提出算法的收敛性。标准粒子群算法用 PSO 表示,惯性权重线性递减的粒子群算法记为 LDPSO,本文所提出的随机位置突变的自适应粒子群算法记为 RMAPSO。用三种方法在 MATLAB2016a 的环境下分别求解 Rastrigin 函数的最小值。Rastrigin 函数的表达式如式(17)

$$f(x) = \sum [x_i^2 - 10 \times \cos(2\pi \times x_i^2) + 10] \quad (17)$$

D 表示自变量的维度。当 D = 2 时,函数图像如图 2 所示。

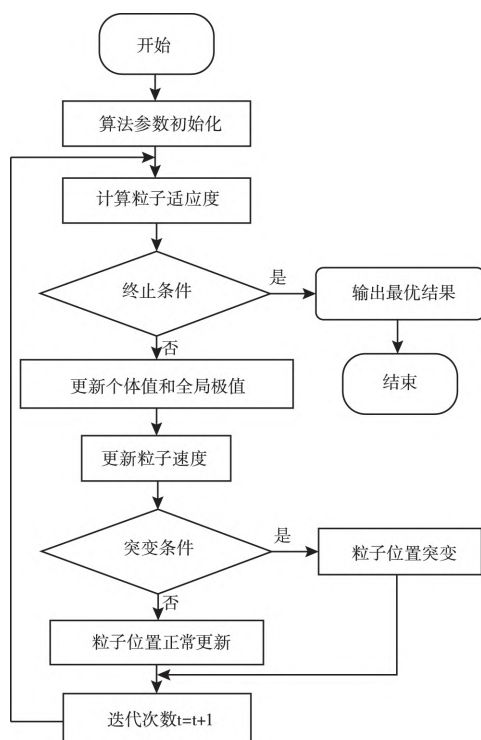


图 2 改进的粒子群算法流程图

这是一个典型的多峰函数,被称为寻优算法的陷阱。该函数的理论最小值为 0,该值在  $x=(0,0,0,\dots,0)$  处取到。现在用三种算法求该函数最小值,三者不同之处在于,PSO 的  $\omega$  值固定为 0.8,LDPSO 和 RMAPSO 的  $\omega$  值均由 0.9 递减至 0.4,前者采取线性递减模型,后者采取式(15)的递减模型。PSO 和 LDPSO 没有位置突变机制,RMAPSO 中加入了随机位置突变机制。除上述的两点差异外,剩余参数均相同并且终止条件设置为准确值最小值 0。三种算法的前 2000 次收敛曲线如图 3 所示。

从图 3 可以看出,三种算法均具有收敛性。PSO 最早收敛,经过 200 次迭代后稳定收敛于 40 附近,收敛效率最高,收敛效果最差。LDPSO 经过近 400 次迭代后稳定收敛于 17 附近,与 PSO 相比,收敛效果有所提升。RMAPSO 迭代 300 次以后收敛于小于 1 的值,在 440 代以后收敛结果已经小于




图 3 Rastrigin 函数的三维图像

0.001,并且最终收敛于  $1.629 \times 10^{-11}$ ,与理论最小值相差小于  $10^{-10}$ ,与 PSO 相比,收敛效果提升显著。在耗时 2 小时 43 分钟 56 秒后,RMAPSO 迭代 640 万次搜索找到了实际最小值 0,此时 PSO 求得的解仍大于 40 且早已固定不变,LDPSO 情况与 PSO 相似,固定收敛于 17 附近。由此可知,本文所提出的 RMAPSO 算法具备收敛性,并且经过改进后收敛效果优于前两种算法,具备求得实际最小值的能力。

## 4 无人机航迹规划的仿真与分析

本实验的整体思路是:首先,建立三维环境模型,包括山峰地形和雷达威胁;其次,设置了由航迹长度代价、雷达威胁代价和偏航角代价构成的代价函数,用此函数来评价一条航迹的优劣;最后,用标准粒子群算法(PSO)、线性递减惯性权重的粒子群算法(LDPSO)和本文提出的随机位置突变的自适应粒子群算法(RMAPSO)在相同条件下做单无人机的静态全局航迹规划一共进行 300 次仿真并记录数据。

### 4.1 仿真环境与参数设置

为了验证本文提出的算法在航迹寻优中的有效性,采用对比实验的方法。本实验的整体思路是:首先,建立三维环境模型,包括山峰地形和雷达威胁;其次,设置了由航迹长度代价、雷达威胁代价和偏航角代价构成的代价函数,用此函数来评价一条航迹的优劣;最后,用标准粒子群算法(PSO)、线性递减惯性权重的粒子群算法(LDPSO)和本文提出的随机位置突变的自适应粒子群算法(RMAPSO)在相同条件下做单无人机的静态全局航迹规划一共进行 300 次仿真并记录数据。

仿真软件是 Matlab2016a,全部实验在 win10 64 位操作系统,Intel(R) Core(TM) i5-10400 CPU, RAM 为 16G 的机器上运行。

环境空间为  $100 \times 100 \times 100$  的三维环境,其中包含 6 座起伏山峰和 2 个雷达站。山峰数据如表 1 所示,包括中心坐标、高度和范围三个属性。环境地形生成后,后续实验均使用这一环境数据。起点、终点与雷达的参数如表 2 所示。PSO、LDPSO 和 RMAPSO 三种算法参数设置如表 3 所示。

表 1 山峰数据

山峰	中心坐标	范围	高度
山峰 1	( 20 ,20)	( 7 ,9)	45
山峰 2	( 30 ,60)	( 5 ,5)	51
山峰 3	( 50 ,50)	( 9 ,6)	62
山峰 4	( 70 ,20)	( 3 ,4)	88
山峰 5	( 85 ,85)	( 4 ,7)	40
山峰 6	( 60 ,70)	( 4 ,5)	74

表 2 地形参数

符号	数值	意义
Star	( 0 ,0 ,5)	起点坐标
End	( 100 ,100 ,40)	终点坐标
s	6	山峰数量
$W_1$	( 80 ,30 ,0)	雷达 1 中心坐标
$W_2$	( 30 ,80 ,0)	雷达 2 中心坐标
$R_1$	20	雷达模型半径
$R_{min}$	20	雷达有效探测半径
$R_{max}$	30	雷达最大探测半径

表 3 算法参数

符号	数值	意义
$k_1$	0.5	航迹长度代价的权重
$K_2$	0.3	雷达威胁代价的权重
$K_3$	0.2	偏航角代价的权重
pop	20	粒子数量
n	5	航迹点数量
N	100	插值后的航迹点数量
$C_1$	1.5	自我学习因子
$C_2$	1.5	社会学习因子
T	2000	最大迭代次数
$\varepsilon$	0.001	差值判断标准
$V_{max}$	10	粒子的最大飞行速度
$W_{max}$	0.9	惯性权重最大值
$W_{min}$	0.4	惯性权重最小值
$\omega$	0.8	固定惯性权重

依照上述表中的数据,生成飞行环境,三种算法分别独立运行 100 次,共计 300 次实验。每次记录各算法最终的收敛结果和收敛到此结果所用的迭代次数以及三维航迹点数据。

#### 4.2 仿真结果与分析

在这 300 次实验中,取出各个算法表现最优的解,其三维航迹如图 4 所示。

在图 4 中,RPMAPSO 算法求得的航迹绕过了图中五角




图 4 三维航迹

星标记的障碍物,而 PSO 与 LDPSO 算法所求得的航迹均未绕过该障碍物。

适应度值如图 5 所示。在图 5 中,纵坐标适应度值代表每一代中最优航迹的综合代价。从图 5 可以看出,三种算法均具备全局寻优能力,可以经过若干次迭代后找到代价较小的可行航迹。具体来说,在 RPMAPSO 的曲线里有这样的特点,在大约 400 到 500 代的区间内,寻优的结果呈平稳状态,且接近于 PSO 的最终结果,同样地,在大约 600 到 700 代的区间内也呈平稳状态,并且接近于 LDPSO 的最终收敛结果,最终在 1300 代以后整体呈现平稳状态,收敛于区间( 7,8) 的某个值。纵观 RMPAPSO 的整个收敛过程,阶梯性更为明显。对比 PSO 和 LDPSO 的曲线图不难发现,LDPSO 收敛结果的质量有所提升,而 RPMAPSO 的提升效果更为显著,面对相同的环境,如果将 PSO 与 LDPSO 的最终结果视为两种局部最优解,那么,RPMAPSO 则具备跳出局部最优解的能力,可以有效防止粒子早熟。结合图 4 的三维航迹图来看,PSO 与 LDPSO 的最终航迹相似程度较高,而 RPMAPSO 的航迹图则与前两者差异较大。这也就是改进算法的性能提升所导致的结果。综上所述,相较于 PSO 和 LDPSO,本文提出的算法在解决航迹规划问题上具备可行性和优越性,并且提升效果显著。




图 5 适应度收敛曲线及局部放大图



### 4.3 复杂环境适应性检验

为了检验 RMAPSO 的适用环境,在多山峰的环境下进行对比实验。起点坐标为(0,0,5),终点坐标为(100,100,40)。本实验中,在不影响实验结果的前提下,为了减少计算量,只考虑航迹长度代价,算法的相关参数设置见表3,实验结果与两点的直线距离进行比较。此部分将采用随机地形进行实验,山峰数量分别为5、10和15。随机生成一次地形后,用三种算法在该地形上进行航迹规划,统计三种算法在不同环境下的最终解以及得到该解所需要的迭代次数,对比 RMAPSO 优化效果的提升程度。实验数据整理如表4所示(表中第一项数值表示最终的航迹长度,保留四位小数;第二项数值表示最早得到这个结果需要的迭代次数,单位:百次)。

表4 适用性检验

山峰数量	PSO		LDPSO		RMAPSO	
5	146.9575	2	146.5437	3	145.9005	4
10	148.5480	3	146.3702	4	145.9028	5
15	177.7052	3	161.0614	5	149.9598	7

起点与终点的直线距离=145.6880

从表4中可以看出,当山峰数量分别为5、10、15时,RMAPSO与PSO得到的最优解差距分别为1.0570、2.6452、27.7454。因此可以得到,随着地形复杂程度的提高,改进的所带来的效果提升越明显,从而表明了,RMAPSO在复杂环境下适用性更好。

## 5 结论

针对粒子群算法解决无人机三维航迹规划时容易陷入局部最优解的问题,提出了一种改进的随机位置突变的自适应粒子群算法。设置一个局部最优的判断参数和记录标记,当满足位置突变条件时,各个粒子速度保持不变并且保存记忆,将它们的位置随机突变到一个其它位置,以此来增加种群多样性。仿真结果表明:与PSO和LDPSO相比,RMAPSO能够在保证安全飞行的同时,得到飞行代价最小的航迹。结合静态全局航迹规划重点关注航迹精度的现实需求,从而可以证明本文提出的RMAPSO算法在解决航迹规划问题上的可行性和优越性。并且通过复杂环境适应性检验证明了,在一定范围内,本文提出的算法的提升效果会随着环境复杂程度增加而提高。

### 参考文献:

- [1] 刘正元,王清华. 无人机在应急物流配送中的任务分配模型构建[J]. 科技管理研究, 2020, 40(24): 229-236.

- [2] 巫茜,罗金彪,顾晓群,曾青. 基于改进 PSO 的无人机三维航迹规划优化算法[J]. 兵器装备工程学报, 2021, 42(8): 233-238.
- [3] 张哲,吴剑,代翼阳,应进,何诚. 基于改进 A-Star 算法的隐身无人机快速突防航路规划[J]. 航空学报, 2020, 41(7): 254-264.
- [4] 李世昌. 基于 A\* 与人工势场法的四旋翼无人机路径规划算法研究[D]. 哈尔滨工业大学, 2017.
- [5] Wei Pan, Xin-lian Xie, Ping He, Tian-tian Bao, Meng Li. An automatic route design algorithm for intelligent ships based on a novel environment modeling method [J]. Ocean Engineering, 2021, 109603.
- [6] 陈华毅. 基于智能优化算法的多无人机协同航迹规划研究[D]. 中国矿业大学, 2020.
- [7] Huang C. A Novel Three-Dimensional Path Planning Method for Fixed-Wing UAV Using Improved Particle Swarm Optimization Algorithm [J]. International Journal of Aerospace Engineering, 2021, 2021.
- [8] 杜云,彭瑜,邵士凯,刘冰. 基于改进粒子群优化的多无人机协同航迹规划[J]. 科学技术与工程, 2020, 20(32): 13258-13264.
- [9] 鲁亮亮,代翼阳,应进,赵玉坤. 基于 APSODE-MS 算法的无人机航迹规划[J]. 控制与决策, 2022, 37(7): 1695-1704.
- [10] 徐浩天. 基于粒子群算法的多维优化改进与应用研究[D]. 哈尔滨师范大学, 2021.
- [11] 姚军,李思捷,罗德林,刘善国,王国耀,吴军. 基于粒子群遗传算法的多无人机协同路径搜索[J]. 火力与指挥控制, 2021, 46(8): 59-63, 70.
- [12] 付兴武,胡洋. 基于改进粒子群算法的三维路径规划[J]. 光电与控制, 2021, 28(3): 86-89.
- [13] Ahmed N, Pawase C J, Chang K H. Distributed 3-D Path Planning for Multi-UAVs with Full Area Surveillance Based on Particle Swarm Optimization [J]. Applied Sciences, 2021, 11(8): 3417.
- [14] 熊华捷,蔚保国,何成龙. 基于改进粒子群算法的 UAV 航迹规划方法[J]. 计算机测量与控制, 2020, 28(2): 144-147.

### 【作者简介】



刘春玲(1971-),女(汉族),辽宁省营口市人,教授,博士研究生,硕士研究生导师,主要研究方向为信号处理,智能控制。

冯锦龙(1997-),男(汉族),山西省太原市人,硕士研究生,主要研究方向为无人机航迹规划,深度学习。

化学习。

田玉琪(1998-),女(汉族),山东省临沂市人,硕士研究生,主要研究方向为异构无线网络。

张琪珍(1997-),男(汉族),河南省安阳市人,硕士研究生,主要研究方向为深度学习。